

Manipulação de dados acelerada por GPU

Bem-vindo(a) ao workshop da Nvidia sobre Fundamentos da Ciência de Dados Acelerada.

Este workshop serve como uma introdução à ciência de dados, com ênfase em velocidade e eficiência.

Foi projetado para cientistas de dados iniciantes e experientes que buscam acelerar fluxos de trabalho e otimizar resultados com GPUs NVIDIA.

Vamos começar. Aqui está uma visão geral do workshop.

Nosso objetivo é orientá-lo pelas principais etapas do fluxo de trabalho de ciência de dados, ajudando você a transformar dados brutos em insights acionáveis.

Essas etapas são amplamente categorizadas em preparação de dados, modelagem, treinamento, inferência e implantação. Os objetivos de aprendizagem deste workshop incluem a compreensão dos conceitos e componentes fundamentais da ciência de dados.

Explorando exemplos práticos de fluxos de trabalho acelerados em ciência de dados, examinando as ferramentas e os métodos usados para alcançar essa aceleração e discutindo suas implicações mais amplas.

Para ajudar você a atingir esses objetivos, organizamos o workshop em três seções. A Seção 1 aborda uma introdução à ciência de dados e à manipulação de dados, a Seção 2 se concentra em análise de grafos e a Seção 3 apresenta uma demonstração prática de diversas tarefas de aprendizado de máquina. Concluiremos com uma avaliação de programação, que permitirá que você aplique o que aprendeu e receba um certificado de conclusão do workshop.

Vamos começar pela Seção 1, onde exploraremos os fundamentos da ciência de dados, discutindo sua importância e aplicações práticas.

Em seguida, vamos explorar a computação em GPU e o Rapids, um conjunto de bibliotecas projetado para habilitar a aceleração por GPU. Isso lhe proporcionará uma compreensão intuitiva de como as GPUs aceleram o processamento de dados.

A seguir, abordaremos detalhadamente os principais métodos de manipulação de dados, preparando o terreno para o laboratório prático onde você aplicará esses conceitos diretamente.

Ao longo do caminho, também discutiremos a visualização de dados e a interoperabilidade de bibliotecas de GPU. Começamos com este slide que demonstra a ampla gama de casos de uso impactantes para a ciência de dados. Em sua essência, a ciência de dados é o estudo de dados para extrair informações relevantes. Informações relevantes que impulsionam aplicações como segmentação de clientes, recomendações personalizadas, detecção de fraudes, otimização da cadeia de suprimentos e manutenção preditiva.

Está no cerne da inovação moderna, demonstrando como os dados se tornaram um ativo vital para as empresas. Frequentemente chamados de petróleo do mundo moderno, os dados são um recurso crítico que, quando aprimorado e utilizado, impulsiona a inovação de forma eficaz, fortalece os negócios e transforma as indústrias.

As empresas que sabem aproveitar seus dados podem obter insights mais profundos, otimizar operações, aprimorar a experiência do cliente e manter uma vantagem competitiva.

No cenário empresarial atual, em rápida evolução, a ciência de dados deixou de ser apenas uma vantagem e se tornou uma necessidade. Ao integrar profundamente a ciência de dados às operações, as empresas podem desbloquear todo o seu potencial e prosperar na economia digital.

A ciência de dados é reconhecida como um campo multidisciplinar que combina princípios e práticas da matemática, estatística, inteligência artificial e engenharia da computação para analisar grandes volumes de dados.

É uma abordagem poderosa usada para fazer e responder a perguntas-chave, como o que aconteceu, por que aconteceu, o que acontecerá a seguir e quais ações podem ser tomadas com base nos resultados. A ciência de dados vai além da análise quantitativa tradicional. análise.

Uma das principais conclusões é que também integra o conhecimento de ferramentas, métodos e tecnologias para extrair informações relevantes e gerar valor a partir dos dados.

Seja para impulsionar decisões mais inteligentes, descobrir novas oportunidades ou resolver desafios complexos, a ciência de dados capacita as empresas a terem sucesso em um mundo orientado a dados. mundo movido.

Um cientista de dados é responsável por tarefas como inteligência de negócios, mineração de dados, análise de negócios, análise preditiva, elaboração de relatórios e visualização de dados.

No entanto, a jornada normalmente começa com dados brutos, que muitas vezes não são imediatamente utilizáveis devido a vários desafios. Esses dados precisam primeiro passar por processamento e preparação antes de poderem ser utilizados de forma eficaz posteriormente.

Embora o aprendizado de máquina e a análise de dados sejam resultados vitais da ciência de dados, as tarefas não analíticas são igualmente importantes para garantir resultados significativos.

A preparação de dados, como ETL (extração, transformação e carregamento), desempenha um papel fundamental em qualquer fluxo de trabalho de ciência de dados. Embora o foco geralmente esteja na análise final dos dados, a preparação de dados é um processo complexo e essencial.

Em modelos preditivos, é a qualidade dos dados de entrada que, em última análise, determina a confiabilidade e o valor dos resultados.

Essa parte do fluxo de trabalho pode consumir mais de 40% do tempo de um cientista de dados.

Um processo ETL adequado garante que os dados brutos de diversas fontes sejam coletados, limpos e tornados utilizáveis para análise.

Pense nisso como construir uma casa. Sem uma base sólida, a estrutura está fadada ao fracasso.

Da mesma forma, dados mal preparados levam a conclusões não confiáveis.

Previsões imprecisas e decisões equivocadas.

Por outro lado, dados limpos e bem preparados permitem que analistas e cientistas de dados se concentrem na geração de valor, em vez de perder tempo corrigindo erros ou reconciliando inconsistências. Em última análise, uma preparação robusta dos dados a montante garante que os dados sejam Preciso, consistente e acessível.

Isso permite que as empresas confiem em suas análises, ampliem seus esforços analíticos e tomem decisões informadas. No mundo dos dados, o mesmo se aplica.

Lixo entra, lixo sai.

Investir em processos robustos de preparação de dados é a base para análises bem-sucedidas. Você pode se surpreender ao saber que os maiores desafios da ciência de dados hoje não estão centrados nas técnicas analíticas em si.

Muitos desses métodos e boas práticas estão bem estabelecidos e são amplamente divulgados. Em vez disso, os principais obstáculos residem no processamento de dados. Frequentemente, ouvimos de nossos clientes sobre problemas como o tamanho e a complexidade crescentes dos dados, bem como a lentidão no processamento dos mesmos.

Além disso, os usuários frequentemente expressam frustração com o ecossistema de software fragmentado. Por exemplo, eles podem depender de bibliotecas separadas para dados, manipulação e aprendizado de máquina, apenas para se deparar com problemas de compatibilidade quando uma biblioteca é atualizada, causando a interrupção dos fluxos de trabalho.

Esses desafios destacam a necessidade de soluções de processamento de dados mais ágeis e eficientes. Para contextualizar, vamos analisar um dia típico na empresa.

A vida de um cientista de dados. O dia geralmente começa com o download de dados do... noite anterior.

Idealmente, os dados chegam em tempo hábil, permitindo que o cientista de dados implemente rapidamente seu primeiro fluxo de trabalho. No entanto, devido ao grande tamanho do conjunto de dados, o processamento pode levar um tempo considerável para ser concluído.

Ao trabalhar com novos conjuntos de dados, é comum esquecer uma etapa ou cometer um pequeno erro. Mas, com uma carga de trabalho intensa de processamento de dados que leva horas, até mesmo erros insignificantes podem atrasar drasticamente o progresso, dificultando a transição da preparação dos dados para a análise.

Isso não apenas prejudica a produtividade, como também limita as oportunidades de exploração e experimentação. Para superar esse problema, precisamos de fluxos de trabalho rápidos, eficientes e que suportem experimentação iterativa. Aqui está um vislumbre do dia a dia de um cientista de dados que utiliza e acelera o fluxo de trabalho computacional.

Com o processamento de dados deixando de ser um gargalo, eles conseguem alcançar maior produtividade, o que lhes permite se concentrar em tarefas mais relevantes.

Eles podem explorar e iterar mais, o que leva a melhores resultados e insights mais profundos. Isso resulta em menor tempo para obter insights e menor custo total.

propriedade, beneficiando tanto o indivíduo quanto toda a equipe.

A aceleração pode ser alcançada aproveitando hardware especializado, como a GPU. Ao adotar a aceleração por GPU, podemos sustentar o crescimento exponencial e o desempenho computacional.

Prevê-se que, até 2025, a computação em GPUs oferecerá um desempenho 1000 vezes superior ao da computação de thread único. Esse avanço notável possibilitou aplicações inovadoras, como sistemas de recomendação e computação em larga escala. modelos de linguagem e análise genômica.

As empresas de hoje dependem desse imenso poder computacional para se manterem à frente da concorrência e resolverem problemas como previsão, detecção de fraudes e segurança cibernética.

A aceleração por GPU é verdadeiramente uma força motriz para a resolução de problemas modernos e para o progresso.

Para entender como a aceleração acontece, vamos analisar mais de perto as diferenças entre uma CPU e uma GPU. A CPU é um processador de uso geral responsável por Gerenciar a maioria das tarefas do sistema, incluindo executar o sistema operacional, lidar com operações de entrada e saída e executar instruções sequenciais de alto nível.

Ele foi projetado para ter um pequeno número de cursos poderosos otimizados para processamento sequencial e tarefas de baixa latência.

Em contraste, a GPU é um processador especializado, construído para processamento paralelo. Ela contém milhares de núcleos menores e eficientes, projetados para lidar com tarefas que podem ser paralelizadas, como operações matriciais e cálculos vetoriais.

Essa diferença arquitetônica existe porque os dois processadores são construídos com objetivos distintos em mente. As CPUs se destacam na execução de poucos threads muito rapidamente e Eficientemente, com foco em tarefas sequenciais. As GPUs se destacam na execução simultânea de milhares de threads, tornando-as ideais para tarefas que exigem altos níveis de paralelismo.

Considere calcular a soma agregada de um grande conjunto de dados carregado na memória de uma GPU. O conjunto de dados é dividido em partes menores, e milhares de threads o processam. calcular as somas parciais de forma independente e paralela.

As somas parciais são então combinadas para produzir o resultado final, acelerando significativamente o processo em CPUs com número limitado de núcleos.

A soma do conjunto de dados envolve o processamento de um ou poucos blocos por vez, de forma mais sequencial. Se essa fosse a única tarefa a ser executada, seria mais rápida na GPU e potencialmente consumiria menos energia.

Nem todas as tarefas se beneficiam da execução por GPU. Para cargas de trabalho que envolvem alto paralelismo, como renderização de vídeo e imagem, aprendizado de máquina e ciência de dados, as GPUs oferecem aceleração significativa.

Ao transferir essas tarefas para a GPU, os sistemas podem alcançar um desempenho mais rápido e maior eficiência. Para realizar cálculos na GPU, os dados precisam ser

Carregado na memória da GPU diretamente do disco ou copiado da memória da CPU.

Ao longo dos slides, frequentemente abordaremos a memória como um fator crucial. Vejamos um exemplo simples envolvendo dados estruturados.

Dados estruturados são definidos por possuírem um formato ou esquema predefinido. Frequentemente, são representados como tabelas ou planilhas originadas de fontes como arquivos CSV.

Planilhas do Excel ou bancos de dados relacionais. Uma vez carregados na memória, os dados estruturados são normalmente representados como um data frame, um formato popularizado pelo Python.

A biblioteca pandas é apreciada por sua flexibilidade e facilidade de uso.

O mundo também contém dados semiestruturados e não estruturados. Como você logo perceberá, a eficiência do processamento de dados depende em grande parte de sua estrutura.

Os data frames são compostos por colunas e linhas, razão pela qual são frequentemente chamados de dados tabulares.

Cada coluna representa uma característica, propriedade ou dimensão, enquanto cada linha corresponde a um registro ou observação individual.

Na memória do computador, esses dados são armazenados como uma matriz. Suponha que precisamos calcular o resultado da diferença entre a coluna um e a coluna dois, multiplicado pela coluna 3A.

Uma abordagem direta envolveria processar uma linha por vez, realizando operações em cada valor sequencialmente. Embora intuitivo, esse método exige a execução de inúmeras operações simples em sequência, o que pode ser demorado.

Consumo para grandes conjuntos de dados.

Ao aproveitar as operações vetoriais, os cálculos podem ser concluídos em muito menos etapas. A ideia principal é que a mesma operação pode ser realizada simultaneamente em vários elementos de um vetor usando vários núcleos.

Essa execução paralela aumenta significativamente o desempenho, pois a potência computacional total escala tanto com o tamanho do vetor quanto com o número de núcleos disponível.

Isso é, obviamente, apenas a ponta do iceberg quando se trata da **tecnologia que torna os GPs tão eficientes**. No entanto, destaca um fator chave por trás de suas capacidades de aceleração: o **paralelismo por meio de operações vetoriais**.

Existem diversas maneiras de interagir com uma GPU, dependendo da sua experiência e dos seus objetivos. No nível mais básico, os desenvolvedores podem escrever código CUDA para aproveitar diretamente os recursos da GPU.

Essa abordagem costuma ser a preferida por programadores experientes que buscam maximizar o desempenho da GPU. Para cientistas de dados, uma opção mais acessível é usar a GPU.

Bibliotecas aceleradoras Python.

Essas bibliotecas geralmente imitam a sintaxe de bibliotecas populares baseadas em CPU, mas internamente invocam código CUDA de baixo nível para ser executado na GPU.

Isso permite que os cientistas de dados aproveitem o poder da GPU sem precisar escrever código CUDA por conta própria.

Esse conceito é conhecido como camada de abstração, que simplifica o fluxo de trabalho à medida que se sobe na pilha de tecnologias. Além disso, não existem plugins que habilitem a GPU.

Aceleração para bibliotecas de ciência de dados amplamente utilizadas sem necessidade de alterações de código internas; esses plug-ins se integram perfeitamente com bibliotecas Python otimizadas para GPU.

Um exemplo disso é o QDF, uma biblioteca acelerada por GPU que proporciona manipulação de dados rápida e eficiente, mantendo uma interface familiar semelhante à de bibliotecas baseadas em CPU.

ferramentas.

QDF é uma biblioteca Python acelerada por GPU para carregar, unir, agregar, filtrar e manipular dados usando uma API no estilo de data frame.

Algumas das funcionalidades incluem entrada e saída eficientes, formato de memória colunar, operações de dados avançadas e a capacidade de escrever funções definidas pelo usuário.

Já mencionamos como isso permite uma análise estatística mais rápida.

Isso também nos ajuda a gerar respostas mais rápidas a partir de visualizações interativas, bem como no pré-processamento de dados e na engenharia de recursos para aprendizado de máquina subsequente tarefas.

O **Apache Arrow** é um formato de dados colunar em memória de código aberto, projetado para análises de alto desempenho e processamento de dados eficiente. Suas principais vantagens incluem o layout de memória colunar.

Os dados são armazenados em colunas, que se alinham perfeitamente para processamento paralelo em GPUs, permitindo operações vetoriais rápidas e eficientes.

Por exemplo, muitas análises de dados envolvem a agregação de valores de uma única coluna. Quando os dados estão em formato de coluna, eles são facilmente acessados sem... a necessidade de ler dados não relacionados.

O Arrow permite o compartilhamento de dados e a interoperabilidade aprimorada, possibilitando o compartilhamento de dados entre bibliotecas sem a necessidade de cópia ou serialização, reduzindo a sobrecarga e melhorando o desempenho, além de otimizar a entrada e a saída de dados. O Arrow acelera a leitura e a gravação de formatos de arquivo colunares, como o Parquet.

Agrupar por operação é uma técnica poderosa que permite aos cientistas de dados dividir os dados em grupos com base em características compartilhadas ou critérios específicos.

Essas operações podem ser usadas de várias maneiras, incluindo funções de agregação, transformação e aplicação. Elas seguem uma abordagem de dividir, aplicar e combinar para produzir um novo quadro de dados.

Agrupar por agregações, como calcular estatísticas descritivas comuns como soma, média, contagem e máximo, é considerado uma função de redução que é executada muito rapidamente.

No entanto, existem certos cenários em que as operações de agrupamento podem não se beneficiar da aceleração por GPU. Considere um caso de uso em que o cientista de dados precisa de

Calcular a diferença entre um valor e a média do grupo.

Isso pode ser implementado usando uma operação de agrupamento por aplicação. A função de aplicação funciona aplicando uma função específica a cada grupo sequencialmente e, em seguida, concatenando os resultados.

No entanto, essa abordagem pode ser muito lenta ao lidar com um grande número de pequenos grupos devido à sobrecarga de processar cada grupo individualmente.

Por outro lado, para um pequeno número de grupos grandes, o desempenho pode ser aceitável. Uma solução alternativa envolve o uso de agrupamento por transformação, que pode ser muito mais eficiente quando cuidadosamente projetado para aproveitar as operações vetoriais. GPU.

As operações vetoriais são essenciais para maximizar o desempenho e permitem uma execução mais rápida em comparação com as abordagens sequenciais.

No entanto, é importante estar atento ao aumento da utilização de memória causado pelos quadros de dados intermediários. A pegada de memória pode ser influenciada pelo número de grupos e pelo tamanho de cada grupo, portanto, um design de código eficiente é crucial para um desempenho ideal.

Nosso objetivo é levar a aceleração por GPU para onde os cientistas de dados já trabalham, minimizando os obstáculos e simplificando a adoção.

Já trabalhamos bastante para acelerar os fluxos de trabalho existentes usando GPUs com QDF sem exigir nenhuma modificação no código.

Conseguimos isso para **o Pandas**, o líder indiscutível no trabalho com dados tabulares, que possui um extenso ecossistema de bibliotecas construídas ao seu redor.

Da mesma forma, habilitamos a aceleração por **GPU para o Polar**, uma biblioteca de dataframes em rápido crescimento, conhecida por sua velocidade e eficiência na manipulação e análise de dados.

Além disso, estendemos essa capacidade a estruturas de **computação distribuída como Dask e Spark**, garantindo que o processamento de dados em larga escala possa aproveitar ao máximo o poder da GPU.

Este slide destaca as diversas maneiras pelas quais você pode integrar a aceleração por GPU aos seus fluxos de trabalho de forma transparente. Ao habilitar essas bibliotecas populares de dataframes, nosso objetivo é oferecer o máximo valor aos cientistas de dados e à comunidade analítica em geral.

A maioria dos cientistas de dados está familiarizada com o Pandas ao trabalhar com dados tabulares.

O Pandas é amplamente adotado devido à sua API flexível e forte compatibilidade com outras bibliotecas, facilitando a colaboração em projetos.

Sua popularidade é tão grande que até mesmo grandes modelos de linguagem a compreendem bem.

Você vê isso quando chatbots baseados em LLM respondem a perguntas de análise de dados usando Data frames do Pandas.

O Pandas é ideal para prototipagem e análise exploratória em conjuntos de dados pequenos.

No entanto, apresenta dificuldades de escalabilidade à medida que o tamanho dos dados aumenta.

Essa limitação existe porque muitas funções do pandas são de thread única, o que significa que elas não utilizam mais de um núcleo da CPU.

Para ajudar os usuários a manter os benefícios do pandas e, ao mesmo tempo, obter melhorias significativas de desempenho, introduzimos um acelerador de GPU com alteração de código A0 chamado **QDF pandas**.

Com o QDF pandas, não é necessário fazer alterações no seu código pandas existente. Basta carregar o QDF pandas ao executar o seu código pandas. Assim, a execução dará preferência às funções e métodos equivalentes do QDF.

Se uma determinada operação não for suportada, o sistema recorre automaticamente ao pandas na CPU. Essa abordagem híbrida garante compatibilidade e desempenho sem interrupções.

Em nossos testes comparativos, esse método demonstrou melhorias de desempenho de até 150 vezes em fluxos de trabalho típicos de análise de dados.

Holers é uma biblioteca de data frames de alto desempenho, construída em Rust e projetada para velocidade, escalabilidade e uso eficiente de memória. Sua arquitetura multithread e modelo de execução preguiçosa, combinados com suporte a formatos de dados modernos, a tornam uma excelente opção.

Opção ideal para processamento de dados em larga escala, onde o desempenho é crucial.

O Polar é uma alternativa moderna e mais rápida ao pandas, particularmente adequada para cargas de trabalho de big data que exigem eficiência e velocidade.

Além disso, os fluxos de trabalho do Polar podem ser acelerados por GPU. Desbloqueando um desempenho ainda maior para tarefas computacionalmente intensivas, um dos principais recursos do Polar reside em sua abordagem "lazy" (preguiçosa). Capacidades de execução e otimização de consultas.

Esses recursos permitem que o Polar otimize as operações antes da execução, garantindo que os cálculos sejam realizados de forma eficiente.

Vamos analisar mais detalhadamente o que isso significa e como beneficia os fluxos de trabalho de processamento de dados. Na execução preguiçosa, as operações não são executadas imediatamente.

Em vez disso, elas são adiadas e combinadas em um plano de consulta lógico.

Essa abordagem permite que o sistema aguarde até que uma ação final, como coletar o resultado, seja acionada antes da execução.

O otimizador de consultas analisa o plano lógico e reorganiza as operações para maximizar a suficiência.

Por exemplo, neste cenário, o mecanismo de execução do Polar filtra de forma inteligente a coluna enquanto o arquivo CSV está sendo carregado, em vez de executar essas etapas separadamente.

Essa abordagem permite que o sistema analise as operações antes da execução, possibilitando a eliminação de etapas redundantes, a reordenação de tarefas para maior eficiência e a minimização do uso de computação e memória.

Ao usar um mecanismo de GPU, a carga de trabalho prioriza a execução na GPU para um desempenho acelerado. Se uma operação não for suportada pela GPU, ela recorre automaticamente à CPU, garantindo um processamento suave e confiável.

Para conjuntos de dados que não cabem em uma única GPU, precisamos usar computação distribuída para escalar o processamento de dados em um cluster de nós de computação que trabalham juntos como um único sistema.

Ao utilizar bibliotecas como o DAS, podemos aproveitar o poder de múltiplas GPUs dentro do mesmo sistema, onde cada GPU atua como um trabalhador individual.

O DAS divide os dados em partes ou partições menores e mais gerenciáveis, mesmo que nos refiramos a elas como um único dataframe DAS. Com essa estrutura, os usuários podem aproveitar APIs familiares no estilo de dataframe, enquanto o Dask cuida da coordenação entre os workers.

O Dask também emprega execução preguiçosa, onde as tarefas não são executadas imediatamente.

Em vez disso, o cliente cria e otimiza um gráfico de tarefas para melhorar a eficiência.

Um agendador então distribui essas tarefas para os nós de trabalho para execução. Isso

Essa abordagem é uma solução poderosa para conjuntos de dados massivos, permitindo escalabilidade e desempenho.

No entanto, é importante monitorar e reequilibrar os dados e as cargas de trabalho entre os nós de processamento quando necessário para garantir o desempenho ideal. Na ciência de dados moderna, temos diversas ferramentas para manipulação e análise de dados, e a escolha da ferramenta certa depende do tamanho dos seus dados, do seu hardware e do seu desempenho. requisitos.

O Pandas é ideal para conjuntos de dados de pequeno a médio porte que cabem na memória. É excelente para prototipagem de fluxos de trabalho e teste de algoritmos devido à sua simplicidade e flexibilidade.

O Polar Shine é especialmente útil ao trabalhar com conjuntos de dados de médio a grande porte em uma única máquina, principalmente quando o desempenho é crítico.

Seu design otimizado para multithreading o torna uma alternativa mais rápida ao Pandas para conjuntos de dados em larga escala que não cabem na memória. Ferramentas como Desk e Spark Excel aproveitam a computação distribuída.

Escolher a ferramenta certa garante o desempenho ideal para suas tarefas de processamento de dados. Seja trabalhando em um laptop, um servidor ou um grande computador, cluster de computação, todos eles podem ser acelerados por GPU. A próxima coisa que podemos fazer é... Com dados, temos a visualização de dados.

É o processo de representar dados graficamente para descobrir padrões, tendências e informações.

Você provavelmente já está familiarizado com tipos comuns de gráficos, como gráficos de dispersão, gráficos de linhas, e gráficos de barras.

Essas ferramentas preenchem a lacuna entre os dados brutos e a compreensão, permitindo-nos enxergar uma história por trás dos dados.

As visualizações não só nos ajudam a comunicar informações importantes no final de um projeto, como também devem desempenhar um papel fundamental durante todo o processo de aceleração e enriquecimento de dados. processo.

Elas nos permitem identificar valores discrepantes, anomalias e padrões ocultos que poderiam passar despercebidos usando métodos puramente analíticos.

As visualizações interativas levam isso adiante, permitindo que os usuários explorem os dados dinamicamente, descubram insights mais profundos e aumentem o engajamento.

No entanto, com grandes conjuntos de dados, as interações podem se tornar lentas e disruptivas.

Para reduzir esse atrito, uma solução acelerada por GPU é essencial.

As bibliotecas Rapids se integram perfeitamente aos fluxos de trabalho de visualização, com muitas ferramentas oferecendo suporte direto a arquivos QDF ou fácil integração.

Por exemplo, podemos combinar as seguintes ferramentas para construir um poderoso mecanismo de visualização: **HV Plot** para criar gráficos interativos a partir de data frames QDF, **data shader** para renderizar conjuntos de dados massivos de forma eficiente e **Q cross Filter** para construir filtros cruzados. Painéis de controle com interatividade multidimensional e Plotly Dash para implantar esses painéis como aplicativos totalmente funcionais.

Em conjunto, essa combinação permite a exploração visual acelerada por GPU em tempo real, mesmo dos maiores conjuntos de dados. O Q Cross Filter é um framework Rapids projetado para conectar visualizações da web à filtragem cruzada acelerada por GPU.

Permite a filtragem interativa e extremamente rápida de grandes conjuntos de dados tabulares via QDF.

Ao eliminar a complexidade de conectar vários gráficos a um back-end de GPU, o **Q Cross Filter** permite que você se concentre em explorar os dados com mais rapidez e facilidade.

Data Shader é uma biblioteca Python para visualização de dados em larga escala, capaz de renderizar conjuntos de dados com milhões ou até bilhões de pontos.

Em vez de desenhar cada ponto individualmente, o Data Shader agrega dinamicamente os dados em pixels, garantindo que a escala seja suficiente independentemente do tamanho dos dados.

A biblioteca utiliza um processo de três etapas para renderizar os dados. A **rasterização agrega** os dados em uma grade de pixels.

A **transformação** aplica operações como sombreamento ou normalização. A **renderização** produz o resultado visual final, proporcionando um desempenho ainda mais rápido em conjuntos de dados massivos.

O shader de dados pode ser acelerado por GPU utilizando Rapids, QDF ou outras ferramentas baseadas em GPU durante a etapa de agregação de dados. Essa integração acelera significativamente o processo de rasterização, tornando-o uma solução poderosa para visualizar conjuntos de dados extremamente grandes com alta eficiência.

Esta é uma excelente oportunidade para discutir a evolução da ciência de dados acelerada por GPU. Embora a aceleração por GPU em si não seja novidade, a NVIDIA vem desenvolvendo otimizações progressivas para processos específicos ao longo do tempo.

No entanto, essas aplicações frequentemente exigiam formatos de dados específicos para diferentes etapas, o que levava a frequentes cópias e conversões de dados ao longo do processo.

Infelizmente, essas operações extras podem reduzir ou anular os ganhos de desempenho obtido através da aceleração por GPU.

Ao expandir a funcionalidade do Rapids, podemos minimizar ou até mesmo eliminar a transferência de dados entre sistemas. Idealmente, todos os processos utilizariam um formato de memória de dados compartilhado, eliminando a sobrecarga causada pela comunicação entre sistemas e garantindo um fluxo de trabalho contínuo e de alto desempenho.

Atualmente, a especificação de **dados colunares Apache Arrow** emergiu como o padrão preferido, com muitas bibliotecas de GPU, incluindo aquelas para **aprendizado de máquina**, sendo construídas nesse formato.

A principal vantagem reside no princípio de cópia zero e no compartilhamento eficiente de dados, o que melhorou significativamente o desempenho e a interoperabilidade entre os sistemas.

Além do que já discutimos, o Rapids garante forte interoperabilidade com o QPY para cálculos de matrizes usando CUDA e com o QDNN, que são amplamente adotados na maioria das estruturas de aprendizado profundo.

Isso significa que o pré-processamento de dados e o QDF podem fluir perfeitamente para fluxos de trabalho de aprendizado de máquina com sobrecarga mínima, permitindo desempenho eficiente e de alta qualidade. Pipelines de dados de desempenho.

Em resumo, o Rapids é um conjunto de bibliotecas aceleradas por GPU, projetado para agilizar fluxos de trabalho de ciência de dados de ponta a ponta na GPU.

Essas bibliotecas aproveitam o CUDA para otimização computacional de baixo nível e são construídas para imitar APIs existentes ou oferecer suporte a plugins de serviço para bibliotecas populares, garantindo Uma transição perfeita.

As bibliotecas Rapids são fáceis de instalar e implementar em diferentes ambientes, seja na nuvem, em um data center ou em sua estação de trabalho, tornando a aceleração por GPU acessível e eficiente para todas as tarefas de ciência de dados. Por fim, ao trabalhar com GPUs, há várias considerações importantes para garantir o desempenho ideal. desempenho.

Monitore a utilização da memória. Utilize operações vetoriais sempre que possível para cálculos mais rápidos. Mantenha os dados na GPU o máximo possível para minimizar a sobrecarga de transferência e diagnostique gargalos para identificar e resolver problemas de desempenho com eficácia.

Ao manter esses princípios em mente, você pode maximizar a eficiência dos fluxos de trabalho com aceleradores de GPU. Vamos lá, faça o laboratório prático.