

A IA generativa é uma área em alta há muito tempo. Lembro-me de quando eu estava na pós-graduação, a modelagem generativa era a grande sensação, e isso foi há mais de 15 anos. Portanto, há pesquisas acadêmicas em IA generativa há muito tempo, mas foi só recentemente que a promessa da IA generativa começou a se consolidar no mercado convencional. E, como exemplo disso, aqui está um diagrama da história dos modelos GPT da OpenAI.

GPT significa Generative Pre-trained Transformer (Transformador Generativo Pré-treinado) e é uma abordagem específica para treinar um modelo de linguagem para entender texto.

A primeira versão foi lançada em 2018. E foi projetada para resolver tarefas de processamento de linguagem relativamente simples, como, por exemplo, entender a classe gramatical de uma palavra específica em uma frase.

Tipo, é um substantivo ou um adjetivo? E a forma como eles fizeram isso foi diferente da forma como as pessoas faziam isso no passado.

No passado, tínhamos uma abordagem mais orientada para a classificação, na qual tentávamos treinar um modelo para prever, por exemplo, se esta palavra é um substantivo ou um adjetivo.

Mas o problema com esse tipo de abordagem de classificação é que não temos dados suficientes para treinar um modelo realmente bom, porque simplesmente não há exemplos rotulados suficientes das classes gramaticais de diferentes tipos de palavras para construir algo que seja preciso o bastante para o que queremos fazer.

Assim, a ideia inicial por trás do GPT era treinar um modelo com uma quantidade enorme de texto. E o modelo aprenderia a estrutura do texto tão bem que seria muito fácil para ele responder a perguntas simples como, por exemplo, qual é a classe gramatical desta palavra.

porque possui uma compreensão muito mais profunda do significado do texto, visto que foi treinado com muito mais dados.

Portanto, esta é uma forma do que chamamos de aprendizado não supervisionado, onde construímos modelos que podem realmente absorver grandes quantidades de dados e, em seguida, usamos essa capacidade para resolver novos problemas.

Mas quando o GPT começou, era bastante simples.

O objetivo principal era melhorar a precisão em linguagens bastante simples. tarefas de classificação.

Mas essa não era a visão final da GPT.

Assim, com o GPT-2, lançado em 2019, começamos a ver capacidades realmente incríveis de geração de texto.

Era expressivo, era extenso, era coerente.

Você poderia pedir para ele contar uma história, por exemplo, sobre unicórnios na América do Sul.

E apresentou todo tipo de detalhes coerentes e consistentes ao longo de um ensaio extenso.

algo que não tínhamos conseguido observar em um modelo generativo.
antes.

Os modelos generativos do passado simplesmente não conseguiam modelar os tipos de dependências de longo alcance necessárias para se ter uma estrutura coerente no texto que está sendo gerado.

Portanto, o GPT-2 representou um grande avanço nesse sentido.

Mas o GPT-3, que surgiu no ano seguinte, foi talvez ainda mais empolgante porque

O modelo ficou dramaticamente maior.

Era cerca de 100 vezes maior.

E por causa disso, conseguiu começar a resolver problemas.

Então, a resolução de problemas com zero ou poucos exemplos, explicarei o que é isso com um pouco mais de detalhes em um instante.

Mas começamos a perceber que o modelo de linguagem não é apenas uma ferramenta para entender textos, mas sim uma ferramenta para resolver problemas.

Com base nisso, houve uma série de melhorias no GPT ao longo do ano seguinte.

ou algo assim.

O WebGPT mostrou como usar modelos de linguagem para incorporar ferramentas como a busca na web, o que, naturalmente, expande drasticamente o alcance da informação que esses modelos podem acessar.

Sem acesso a ferramentas,

Esses modelos precisam armazenar todos os fatos do conjunto de treinamento que aprendem como um processo de tentativa de compreender a estrutura da linguagem em seus parâmetros.

Mas, com a capacidade de usar ferramentas, esses modelos podem então recorrer a fontes externas de informação ou a fontes externas de ação para resolver problemas.

O InstructGPT demonstrou que poderíamos obter capacidades de resolução de problemas dramaticamente melhores e também alinhar o modelo para que ele siga melhor os valores e princípios humanos, utilizando o feedback de humanos no processo de treinamento.
modelos.

E então o ChatGPT, que surgiu no final de 2022, é onde esse modelo estava.
ampliado para melhor compreensão

Interações de múltiplas etapas e, de fato, onde vimos isso se popularizar, com extraordinárias capacidades de interatividade e geração de texto.

Então, embora possa parecer que estamos vivendo um momento de IA generativa em que, de repente, vemos essas aplicações surgirem e serem surpreendentes, a área já vem trabalhando nisso há muito tempo.

E, sabe, acreditamos que ainda haverá muito mais progresso pela frente.

Então, quero falar sobre modelos de linguagem com mais detalhes.

Uma das razões pelas quais os modelos de linguagem são tão úteis é que toda a atividade humana é descrita pela linguagem.

Então, tudo o que sabemos fazer, seja resolver problemas de matemática ou praticar esportes ou

Todas as estruturas legais que possuímos estão codificadas na linguagem.

E fazemos isso porque a linguagem é composicional.

Assim, as palavras se combinam para formar novos significados, e podemos nos expressar.

E podemos usar isso para transmitir ideias.

Podemos usar isso para resolver problemas.

Se você se lembra de quando fez uma prova, sabe, o professor anota a questão que você deve resolver, e então

Agora cabe a você fornecer uma resposta.

Como a pergunta e a resposta são ambas descritas em termos de linguagem, se tivéssemos um modelo capaz de entender a linguagem muito, muito bem, então teríamos um modelo que poderia de fato resolver problemas.

Quando estamos treinando um modelo de linguagem, existem algumas maneiras de fazer isso, mas geralmente é bastante simples.

Uma das maneiras mais comuns de treinar um modelo é simplesmente prever a próxima palavra em um sequência.

Então, aqui embaixo,

Temos aqui um trecho de uma música da Disney, "The Wonderful Thing About Tiggers".

E se você reparar, a cada passo, escolhemos uma palavra, e depois há uma série de outras. de diferentes palavras que poderiam seguir essa.

Assim, a sequência de palavras "The Wonderful Thing About Tiggers" é apenas um exemplo específico do modelo de linguagem, mas poderiam existir muitos outros.

Assim, o objetivo do modelo de linguagem é, dado o passado

Em um documento, preveja qual será a próxima palavra.

E como esse é um objetivo de treinamento tão simples, podemos aplicá-lo a todos os textos que encontrarmos na internet.

E não precisa ser tudo no mesmo idioma.

Podem ser linguagens de programação.

Podem ser todos os diferentes tipos de línguas humanas.

Assim, podemos coletar todo o texto da internet e treinar o modelo para prever a próxima palavra.

E se o modelo for capaz de fazer isso com precisão, então sabemos que ele realmente entende o conteúdo do texto e é capaz de construir algumas estruturas internas que correspondem ao conteúdo do texto e, de fato, começar a raciocinar sobre esse texto para produzir a melhor previsão para a próxima palavra.

E talvez você já tenha passado por isso, se alguma vez usou a função de previsão da próxima palavra no seu celular, por exemplo, enquanto digitava uma mensagem de texto, e as sugestões que ela oferece geralmente não são muito úteis.

Isso acontece porque os modelos que estão sendo usados atualmente no seu celular para prever a próxima palavra não entendem de fato o que você está tentando dizer.

Mas se você tivesse um modelo que entendesse o que você está tentando dizer, então você poderia imaginar que seria dramaticamente mais fácil construir um modelo que fosse útil para isso. tarefa.

Agora, outro detalhe técnico que acho importante mencionar é que os modelos não operam diretamente sobre as palavras, o que seria de se esperar se estivéssemos treinando um modelo capaz de entender textos em todos os idiomas, já que existem muitos tipos diferentes de palavras e muitos idiomas diferentes.

As definições são todas diferentes.

E assim, as linguagens de programação são algo completamente diferente.

Então, como podemos unificar esses dois aspectos?

Bem, nós construímos o que chamamos de tokens, que são basicamente subpalavras, como partes de palavras.

E fazemos isso analisando nosso conjunto de treinamento, trilhões e trilhões de tokens, e tentando descobrir quais são os tokens mais importantes.

Construímos um vocabulário dessas subpalavras, que podem ser como meia palavra ou então.

E então temos uma espécie de representação de propósito geral que pode codificar texto de forma eficiente.

E é assim que treinamos esses modelos.

OK.

Então, eu estava falando sobre aprendizado com poucos exemplos e aprendizado sem exemplos, e quero descrever um pouco o que isso significa.

À esquerda, tenho um exemplo de uma questão de tradução com poucos exemplos.

Então, a ideia aqui é descrever meu problema com alguns exemplos de solução, problema por problema.

Então, o que estou dizendo é o seguinte:

Estou escrevendo uma frase em inglês e depois a forneço.

E então escrevo a mesma frase em espanhol e, em seguida, dou o exemplo em espanhol.

E eu faço isso algumas vezes.

Então, peço à modelo que traduza algo do inglês para o espanhol, fornecendo uma frase em inglês e dizendo, sabe, dois pontos em espanhol.

E então deixe o modelo completar a frase.

E essa é uma configuração de tradução com poucos exemplos, porque eu forneci ao modelo alguns exemplos, e então a tarefa de completar o texto fica mais óbvia para o modelo do que estou pedindo para ele traduzir.

O mais incrível sobre o aprendizado com poucos exemplos é que os modelos de linguagem podem aprender com poucos exemplos, como demonstrado no artigo do GPT-3 em 2020.

O mais incrível nisso é que

Este modelo não foi treinado para realizar traduções.

Nunca foi exibido.

inúmeros exemplos de textos paralelos, como seria de esperar num sistema de tradução tradicional.

Ele foi treinado com uma enorme quantidade de texto da internet.

E para que entenda que estou pedindo para que uma tarefa de tradução seja resolvida, precisa saber muitas coisas sobre linguagem, a estrutura da linguagem, a ideia de que existe uma língua inglesa e uma língua espanhola, e que são línguas separadas com vocabulários e gramáticas diferentes.

mas existe uma correspondência, mesmo que não seja direta e mesmo que não seja uma correspondência linear entre essas línguas.

E então precisa entender que, quando eu digo inglês, dou uma frase e depois dois pontos em espanhol, sem fornecer mais informações, estou pedindo que faça uma tradução.

E então precisa usar todo o conhecimento que possui sobre linguagem, a estrutura da linguagem, o vocabulário e a gramática do inglês e do espanhol, para de fato realizar...

essa tradução.

Portanto, a resolução de problemas com poucos exemplos é realmente incrível.

Quando vi pela primeira vez um de nossos modelos de linguagem na NVIDIA realizando tradução com poucos exemplos, fiquei impressionado, pois me pareceu uma tarefa de alto nível.

Sabe, se um modelo consegue aprender a traduzir entre idiomas sem nunca lhe ser ensinado explicitamente nada sobre o fato de que os idiomas existem e quais são seus vocabulários e gramáticas, imagine todas as outras coisas que ele poderia fazer.

E isso foi realmente emocionante.

Mas, desde então, fomos além disso.

E agora, com o ChatGPT e as tecnologias que acompanham os modelos de linguagem de última geração, estamos realmente vendo a resolução de problemas sem nenhum exemplo surgir.

E isso é ainda mais empolgante. Então, qual é a diferença? Bem, se você olhar à direita, eu tenho um exemplo de tradução sem nenhum exemplo.

O que estou fazendo é pedir explicitamente ao modelo para traduzir, e então forneço uma citação do inglês para o espanhol. Depois, deixo o modelo concluir a tradução, e ele simplesmente me dá a resposta. O motivo pelo qual isso é chamado de "zero-shot" é que eu não forneci nenhum exemplo do que espero que ele faça.

Acabei de descrever o problema. E o modelo é suficientemente geral para conseguir entender o problema que eu estava apresentando sem que eu precisasse dar um exemplo.

diretamente por mim. E isso é resolução de problemas sem nenhuma tentativa, e é incrivelmente... de valor.

Quando pensamos nas diferentes maneiras pelas quais os modelos de linguagem estão sendo usados para resolver problemas em todos esses campos diferentes, como mencionei no início, o fato de esses modelos poderem fazer isso sem que lhes sejam dados vários exemplos do que precisa ser feito os torna muito mais universalmente aplicáveis.

E isso só é possível devido à enorme quantidade de dados com que esses modelos foram treinados e ao tipo de expressividade das redes neurais que estão sendo usadas para entender a estrutura da linguagem.

Aqui está outro exemplo de raciocínio sem exemplos que encontrei no Twitter outro dia. Alguém chamado Zach Whitten estava conversando com o modelo de linguagem que está sendo implementado no Microsoft Bing.

E descobriu-se que esse modelo realmente consegue jogar xadrez. À direita, você pode ver um vídeo da partida. E, de alguma forma, esse modelo é capaz de fazer movimentos legais, que geralmente são bons. Ele consegue explicar o raciocínio por trás deles.

E, segundo Zach, o jogo tem um toque dramático, então apresenta algumas jogadas interessantes. E se você olhar à esquerda, pode ver como fica. Ele está descrevendo o problema em texto. Ele está perguntando: "Quais são os lances restantes em uma partida de xadrez?"

Então ele fornece uma série de movimentos usando uma espécie de código que costuma ser usado em textos para descrever xadrez. É como uma linguagem específica para tabuleiros de xadrez. E então ele pede ao modelo para completar a partida, e descobre que o modelo é realmente capaz de fazer isso.

Para que um modelo de linguagem seja capaz de... executar jogadas de xadrez interessantes e válidas, ele precisa construir implicitamente uma representação do espaço de estados de um tabuleiro de xadrez, entender o que é permitido nesse espaço e manipulá-lo. E o fato de o modelo ser capaz de fazer isso sem nunca ter sido treinado em xadrez é realmente impressionante.

Foi treinado com enormes quantidades de texto, muitos dos quais incluem dados sobre xadrez e incluir a sublinguagem personalizada para descrever o tabuleiro de xadrez. Então, já tinha visto coisas sobre xadrez antes, mas nunca lhe foi dado o objetivo de se tornar bom em jogar xadrez. Mas como a tarefa de modelagem de linguagem é tão poderosa e geral, para realizar a modelagem de linguagem, também teve que descobrir como jogar xadrez. xadrez.

E em algum lugar dentro desse modelo, existe uma representação de um tabuleiro de xadrez que pode ser útil para jogar novas partidas. E essa partida não é uma partida que existia apenas antes.

a internet. Então não se trata apenas de o modelo estar repetindo e ter memorizado os movimentos de um jogo específico que era muito famoso e depois simplesmente jogá-los. Voltar. Não é esse o caso.

O modelo está realmente raciocinando sobre isso, tem sua própria representação interna. E acho isso bastante profundo se você pensar bem, que seja possível um modelo treinado em uma tarefa tão geral como prever a próxima palavra aprender a fazer algo muito específico como jogar xadrez. Isso é extraordinário.

E quando pensamos em todas as diferentes maneiras pelas quais gostaríamos de aplicar esses modelos, fica muito mais claro que eles podem, de fato, ter sucesso na resolução de muitos problemas devido a essa generalidade e à sua capacidade de raciocínio.

Outra coisa que está surgindo e que considero muito importante nesses modelos de linguagem é que eles podem ser treinados para usar ferramentas.

E a forma como isso acontece é que você pode descrever no texto de treinamento, especialmente no texto de ajuste fino, que abordaremos em breve, alguns exemplos de como é usar uma ferramenta.

E existem muitos tipos diferentes de ferramentas. Por exemplo, usar a busca na web para gerar citações que podem conter links para fontes factuais que você pode usar para verificar se um determinado fato dentro da geração está correto. O modelo está correto.

Mas poderia ser algo mais geral. Poderia incluir a execução de várias ações em programas complexos como o Adobe Photoshop ou o 3DS Max. Poderia incluir instruções sobre como um robô deve navegar ou resolver problemas. Poderia incluir

A capacidade de escrever código de computador, como, por exemplo, escrever um script em Python para resolver um problema. E assim podemos ver que, como a linguagem é composicional, podemos usá-la para expressar novos pensamentos e novas ideias, e também para descrever como usar ferramentas.

E podemos usar a linguagem para descrever qualquer ferramenta. E então podemos treinar o modelo para que ele realmente aprenda a usar essas ferramentas. Isso significa que podemos começar a compor as ferramentas que temos, todos os diferentes tipos de ferramentas que temos para manipular informações, usando modelos de linguagem. E eu acho isso muito empolgante e algo que veremos muito no futuro. Ok, então eu mencionei o ajuste fino. Vamos falar um pouco sobre isso.

Então, quando começamos com o modelo de linguagem e fazemos o que chamamos de etapa de pré-treinamento, treinamos o modelo com quantidades enormes de dados, trilhões e trilhões de tokens. Isso para que ele entenda o texto em todas as suas diferentes formas. Mas acontece que Entender o texto em todas as suas formas não é necessariamente a melhor ferramenta para realizar

resolução de problemas. Uma das razões pelas quais isso pode acontecer é que o texto na internet não é escrito como uma sequência de pares problema-solução.

Sabe, quando você acessa um artigo de notícias e o lê, ele tem um título e o corpo do artigo com todo tipo de informação.

Mas o que nunca consta é algo como a declaração do problema, talvez do editor do jornal dizendo: "Por favor, escreva um artigo sobre as negociações mais recentes sobre mudanças climáticas que estavam acontecendo em uma cúpula da ONU. E precisa incluir os seguintes fatos e precisa ter este tamanho." Nenhuma dessas instruções está incluída no texto que você lê online.

As instruções geralmente são implícitas. Isso significa que os modelos, se forem pré-treinados apenas com todos os textos da internet, não serão tão bons quanto poderiam ser em seguir instruções e resolver problemas.

E assim, descobrimos que podemos influenciá-los adicionando feedback humano cuidadosamente. para que os modelos se tornem muito melhores na resolução de problemas.

E um exemplo disso, novamente, vem da OpenAI. Trata-se do artigo deles sobre o InstructGPT, onde descrevem uma abordagem em três etapas para isso.

A primeira etapa consiste em coletar dados de demonstração e, em seguida, ajustar o modelo para criar uma política que siga esses dados.

Por exemplo, vamos receber uma série de enunciados de problemas e, em seguida, as soluções para esses problemas, escritas por especialistas que realmente sabem como resolvê-los. para escrever essas soluções.

Obtemos um pequeno número desses exemplos, um número relativamente pequeno, e ajustamos o modelo de linguagem para que ele entenda que sua função principal é resolver problemas. Vamos apresentar um problema e, em seguida, uma solução. Esse é o primeiro passo.

Depois de termos um modelo um pouco melhor na resolução de problemas, podemos aprimorá-lo ainda mais na capacidade de seguir instruções, usando humanos em vez de escrever as instruções para o modelo. Na verdade, pedimos aos humanos que avaliem as saídas do modelo e digam qual é a melhor.

Assim que o modelo começar a mostrar alguns sinais de funcionamento, ora apresentando bons resultados, ora apresentando resultados ruins, podemos simplesmente classificar as saídas do modelo e usar essas informações para refinar o modelo ou a política. Essa é a segunda etapa.

E então, na terceira etapa, podemos usar o que é chamado de aprendizado por reforço para, de certa forma, testar o modelo contra si mesmo. Então, amostramos um estímulo.

Então, geramos uma saída, usamos o modelo de recompensa para verificar se essa saída é boa ou não e, em seguida, usamos isso para atualizar o próprio modelo. Assim, o modelo basicamente começa a competir consigo mesmo e passa a ser capaz de gerar respostas que são ainda mais úteis.

E, portanto, acredito que uma forma realmente importante pela qual esses modelos de linguagem estão sendo aplicados a diferentes tipos de problemas em diferentes domínios é por meio do uso de ajuste fino supervisionado e aprendizado por reforço com feedback humano.

Vale ressaltar também que esse processo pode tornar o modelo não apenas mais útil, mas também mais seguro. Portanto, alinhar o modelo aos valores humanos é um desafio.

Esses modelos, por terem contato com todos os tipos de linguagem, também veem linguagem questionável. E às vezes são expostos a vieses presentes nos textos, simplesmente porque os humanos expressaram esses vieses em textos na internet, e os modelos os captam.

Gostaríamos de poder influenciar o modelo para que, ao gerar resultados, eles estejam alinhados com nossos valores e não apenas com o que ele viu na internet, porque algumas dessas coisas simplesmente não são apropriadas.

E assim, descobrimos que a mesma tecnologia que torna o modelo mais eficiente em seguir instruções também pode ser usada para torná-lo mais seguro e alinhado aos nossos valores. E acho isso realmente interessante. Frequentemente existe essa tensão.

Em pesquisas sobre modelos de IA, existe essa ideia de que, se quiséssemos criar o

O fato de ser um modelo mais seguro de usar e menos problemático também significaria que seria um modelo menos potente.

Mas com essa abordagem que estamos vendo agora, acontece o contrário: como conseguimos instruir o modelo a estar mais alinhado com os valores humanos, também conseguimos usar essa mesma abordagem para instruí-lo a ser melhor na resolução de problemas, de modo que o modelo possa ser mais útil para nós, em vez de menos útil.

Então, acho que isso é realmente importante.