

Certo, então eu estava falando sobre linguagem, e agora gostaria de falar sobre outras coisas.

Portanto, os modelos de conversão de texto em imagem têm sido realmente empolgantes.

Modelos de imagem para imagem, nos quais podemos resintetizar imagens e editá-las.

Também estamos vendo muitos modelos 3D baseados em texto.

Por exemplo, este 3D

O objeto foi criado a partir de uma entrada de texto que dizia: "Faça para mim um modelo 3D de um astronauta".

Quando pensamos no omniverso, quando pensamos em mundos virtuais e em como as pessoas irão interagir umas com as outras para resolver problemas nesse omniverso, fica claro que a IA generativa terá um papel fundamental, pois esse ambiente virtual será povoado por conteúdo que criaremos usando IA generativa.

A IA generativa também pode ser aplicada a outras formas de dados, como fala e vídeo.

Aqui estão alguns exemplos de fala.

A primeira é aquela em que coletamos uma pequena quantidade de dados.

Temos um modelo TTS, um modelo de síntese de fala, que foi treinado com uma vasta quantidade de dados de milhares de falantes.

E então podemos pegar uma pequena quantidade de dados, digamos, por exemplo, dados da minha voz, onde eu passo meia hora gravando.

Em um estúdio, para obter uma voz personalizada e, em seguida, resintetizar, digamos, minha voz em inglês, o idioma que eu falo nativamente, mas também me permitir falar em um novo idioma.

Aqui está um exemplo de síntese de fala na língua nativa de um falante que recebeu apenas uma pequena quantidade de dados.

Dizem que a noite é mais escura antes do amanhecer.

Estamos nesta cidade há muito tempo.

E então, sem precisar ensinar essa pessoa a falar hindi, podemos capacitá-la a falar hindi usando outro modelo generativo.

Existem, portanto, muitas formas diferentes que a IA generativa pode assumir, muitas formas diferentes. modalidades.

E o interessante é que eles estão começando a se compor e se unir.

Como eu estava falando antes, era sobre como os modelos de linguagem podem usar ferramentas.

Bem, também podemos conectar modelos de linguagem com modelos de síntese de imagem, modelos de síntese 3D, modelos de síntese de fala e modelos de síntese de vídeo, a fim de criar modelos capazes de compreender e sintetizar conteúdo em diversos formatos.

modalidades.

E acho que essa será uma tendência para o próximo ano ou mais.

E como funciona essa composição?

Bem, a composição acontece por meio de incorporações.

E vou dar um exemplo de incorporação de imagens, que são capazes de conectar imagens e texto.

Esta, mais uma vez, vem da OpenAI.

Chama-se Clip.

E a ideia é que, se você conseguir reunir uma grande quantidade

Conjunto de treinamento de imagens com legendas, talvez legendas bem simples que descrevam o conteúdo da imagem.

Você pode realizar uma etapa de treinamento onde criamos um espaço abstrato que nada mais é do que um conjunto de vetores, no qual projetamos cada uma dessas imagens e cada um desses exemplos de texto usando uma rede neural.

E então, quando treinamos a rede neural

Na verdade, estamos treinando o sistema para que, se você tiver um rótulo para uma determinada imagem, ela tenha a mesma representação vetorial nesse espaço vetorial.

Mas se você tiver uma imagem e um rótulo que não combinam, eles deverão ter uma representação vetorial muito diferente.

Essa é uma regra muito simples para treinar uma rede neural.

Tipo, essas coisas são a mesma coisa?

Em seguida, tente fazer com que a saída deles seja a mesma.

Se não forem iguais, tente fazer com que a saída seja diferente.

E podemos descrever isso matematicamente e então treinar um modelo em um enorme conjunto de dados. quantidade de dados.

E então temos um embedding.

Assim, quando quisermos usar esse recurso incorporado, podemos usá-lo com texto.

Por exemplo, podemos pegar esse texto e incorporá-lo ao espaço.

E então podemos usar

um modelo de síntese de imagem para ir desse espaço de incorporação de volta a uma imagem.

Ou podemos fazer o contrário.

Podemos usar uma imagem, passá-la por esse espaço e obter um vetor que, por sua vez, pode ser transformado em texto. Esse texto, então, podemos usar, por exemplo, para entender o conteúdo das imagens.

E como todas essas coisas são muito gerais, você sabe, você pode imaginar que elas sejam compostas em redes neurais que realmente consigam entender e gerar dados de todos os tipos de domínios diferentes.

E isso só é possível graças a vastas quantidades de dados.

Por exemplo, o conjunto de dados LION 5B contém cerca de 6 bilhões de imagens com texto.

Cerca de 2 bilhões dessas imagens são, na verdade, acompanhadas de texto em inglês que descreve o conteúdo delas.

Cerca de 2 bilhões são de outras 100 línguas.

E depois há cerca de 1 bilhão de imagens que

Na verdade, não possuem uma língua associada.

É como, por exemplo, o nome de um objeto, que não é específico de nenhum idioma.

Isso dá uma ideia da escala dos dados necessários para construir esses modelos fundamentais capazes de incorporar texto e imagens no mesmo elemento.
espaço.

Mas agora que temos esses dados incorporados, podemos começar a fazer coisas incríveis.

Aqui estão alguns exemplos de geração de texto a partir de imagens usando os modelos Edify da NVIDIA nos quais temos trabalhado.

Acho que esses modelos são muito interessantes porque nos permitem explorar novas ideias visualmente, usando texto.

E para aqueles de nós, como eu, que não somos artistas, é realmente um grande desafio...

Criar novas imagens que descrevam as ideias que estou tendo, porque simplesmente não tenho a habilidade técnica para pintar.

Mas esses modelos são realmente capazes de compor ideias e gerar imagens de coisas novas que possam me interessar.

Mas os modelos podem fazer mais do que apenas converter texto em imagem.

Aqui está um exemplo de como usar o modelo para controlar efetivamente a saída da imagem.

À esquerda,

A pessoa está desenhando uma espécie de caricatura de onde diferentes tipos de objetos devem ser colocados.

E o número de tipos diferentes de objetos é ilimitado, porque cada um desses objetos está sendo descrito usando a linguagem.

Por exemplo, temos o mago coelho, que lança uma bola de fogo, e o coelho está sentado em nuvens.

E então o texto que acompanha descreve toda a cena, mas nós a controlamos com esse desenho animado que dá ao modelo uma ideia de onde algo deve ficar.

Portanto, essa é uma nova e empolgante capacidade para esses modelos de síntese de imagens, porque agora eu posso realmente construir imagens onde as coisas estão nas posições que eu escolhi.

E, mais uma vez, tudo isso acontece graças à magia desses modelos enormes e dessas incorporações gigantescas.

Esses modelos também podem sintetizar elementos usando referências de estilo.

Por exemplo, vamos pegar uma pintura famosa de Van Gogh junto com um texto que descreve uma cena e usar isso para sintetizar uma nova imagem que tenha todos os elementos que queríamos, mas que se pareça com outra imagem.

Aqui estão alguns resultados do modelo Magic 3D no qual a NVIDIA vem trabalhando.

E, sabe, isso indica que esses modelos funcionam em outros espaços além do das imagens.

Neste caso, estamos criando geometria 3D.

E você pode imaginar que esses 3D

Os objetos podiam ser pintados com texturas, sombras e materiais derivados também de modelos generativos, a fim de criar novos tipos de objetos que poderiam ser inseridos em um mundo virtual como o Omniverso.