

Já falei um pouco sobre o que é IA generativa. Falei sobre algumas de suas aplicações. Falei sobre algumas das tecnologias usadas para construí-la.

Agora, gostaria de falar sobre alguns dos desafios e algumas coisas em que acho que ainda precisamos trabalhar antes que a IA generativa seja totalmente implementada. Uma delas, obviamente, é que a IA generativa frequentemente apresenta erros. Então, quando analisamos o resultado, seja uma imagem, um vídeo, um texto ou qualquer outra coisa,

Os modelos costumam ser muito confiantes. Eles produzem resultados plausíveis, mas que podem estar completamente errados. Então, por exemplo, se você fizer uma pergunta a um desses modelos, não há garantia de que receberá uma resposta factual.

E isso é um problema quando pensamos em como esses modelos estão sendo implementados. Acredito que a comunidade científica está apresentando diversas ideias para tornar esses modelos mais factuais e confiáveis, e veremos muitos avanços nessa direção.

Sabe, um dos motivos pelos quais estou tão confiante nisso é simplesmente porque trabalho nessa área há tempo suficiente e testemunhei a quantidade extraordinária de progresso que ocorreu nos últimos 15 anos para nos trazer até onde estamos hoje.

E acho que superamos desafios enormes para criar os modelos que temos hoje. Ainda temos grandes desafios pela frente para desenvolver plenamente o potencial desses modelos, mas há tantas pessoas inteligentes trabalhando nisso que acredito que veremos muito progresso. Os dados de treinamento também são muito importantes e representam um desafio para a IA generativa.

Então, de várias maneiras. Um dos problemas com os dados de treinamento é que, embora construamos esses modelos coletando o máximo de dados possível de todas as fontes disponíveis, sempre haverá dados corretos e...
Dados incorretos.

Haverá vieses nos dados, porque é isso que acontece na internet. Existem diversos tipos de dados e ideias que as pessoas têm, algumas corretas, outras com as quais discordamos, algumas prejudiciais e outras que não deveriam ser expressas.

Então, como encontramos tudo isso? Como organizamos? Como criamos os modelos?
robusto contra isso?

Isso é realmente importante. E então, claro, como corrigimos os vieses que encontramos? Mas também existem outros desafios. Uma das coisas que acredito ser verdade sobre os dados é que quanto mais valioso um conjunto de dados, mais proprietário ele tende a ser. E isso precisa ser assim. Por exemplo, dados médicos são muito valiosos, mas

Precisa ser mantido em sigilo porque concordamos, como sociedade, que dados médicos não devem ser compartilhados aleatoriamente na internet.

E isso é realmente importante para nós. Portanto, não é uma boa ideia treinar um modelo com todos os tipos de dados proprietários que devem ser mantidos confidenciais, porque

Não sabemos como treinar esses modelos para guardar segredos.

Não sabemos como treinar esses modelos para que observem a confidencialidade.

Isso significa que haverá necessidade de esses modelos serem especializados de maneiras específicas, permitindo que resolvam problemas em novas áreas, viabilizadas por dados proprietários e confidenciais, mas mantendo a confidencialidade desses dados.

E acho que esse é um grande desafio para a IA generativa, e teremos que trabalhar para descobrir como fazer isso acontecer.

Também temos outros desafios bastante significativos.

Então, em relação à propriedade intelectual, houve alguma controvérsia, talvez você já tenha visto algo a respeito, sobre alguns desses modelos de síntese de imagens que foram treinados com todas essas 5 bilhões de imagens da internet.

O problema é que alguns desses artistas, fotógrafos ou criadores prefeririam que suas imagens não fossem incluídas em um desses modelos, porque se o modelo consegue extrapolar ou reproduzir algo que lembra o criador de sua obra, mas ele não recebe o devido crédito ou não deu seu consentimento, isso é um grande problema.

E isso também tem a ver com muitas aplicações comerciais.

Por exemplo, se você estiver criando um modelo para gerar publicidade personalizada para sua marca específica, você vai querer garantir que o modelo só exiba imagens e textos que correspondam à identidade e aos valores da sua marca.

Por exemplo, se você estiver criando um modelo para fazer propaganda da Marvel Comics, seria muito ruim se o modelo comesse a fazer propaganda da Disney, porque não foi para isso que você criou o modelo, e também seria uma violação de direitos autorais e marcas registradas.

Assim, existem muitos desafios em relação a esses modelos, porque sua potência depende do treinamento com uma quantidade enorme de dados.

Mas isso também significa que, às vezes, pode ser difícil manter o foco. E, portanto, pode ser um desafio provar que um modelo será seguro para uso e que refletirá a finalidade para a qual foi projetado.

Portanto, temos muito trabalho a fazer, tanto em termos de treinamento de modelos personalizados que sejam mais restritos, mas ainda úteis, quanto na implementação de mecanismos de segurança para que os modelos sejam mais controláveis e também no alinhamento dos modelos com as preferências humanas para que sejam mais seguros de usar.

Portanto, este será um trabalho contínuo, e não creio que seja um trabalho fácil, e não acho que jamais será totalmente concluído.

Mas, ao mesmo tempo, sei que estamos progredindo bastante e encontrando cada vez mais aplicações em que podemos ter certeza de que esses modelos podem ser implementados.

Um dos maiores desafios da IA generativa é o treinamento e a implantação dos modelos, pois eles precisam ser treinados com uma quantidade enorme de dados, e os próprios modelos são bastante grandes e possuem muitos parâmetros.

A NVIDIA tem trabalhado com o resto da indústria há muito tempo para otimizar cada parte da pilha necessária para treinar esses modelos. E eu gostaria de...

Para falar sobre isso com um pouco mais de detalhes.

O NVIDIA NEMO é, portanto, nossa coleção de frameworks para treinamento de modelos para empresas, e temos otimizado significativamente a velocidade de treinamento de seus modelos de linguagem nos últimos anos.

Por exemplo, ao treinarmos modelos de linguagem de grande porte, podemos atingir mais de 50% da velocidade máxima teórica dos núcleos tensores da máquina durante a execução. em milhares de GPUs simultaneamente.

E essa é uma conquista extraordinária que exigiu o trabalho de milhares de pessoas na NVIDIA e em toda a indústria para otimizar cada parte do processo. pilha.

Os núcleos tensores, os processadores da GPU, os caches, o subsistema de memória da GPU, a interconexão entre GPUs dentro de um mesmo servidor, a conexão CPU-GPU, o software que roda entre eles, a rede entre servidores em um data center e toda a arquitetura do data center. Os frameworks, os

Os frameworks de aplicativos, em geral, envolvem uma grande quantidade de tecnologia que se une para proporcionar ganhos de velocidade transformadores na modelagem de linguagem.

E temos investido há muito tempo não apenas em desempenho, mas também em flexibilidade para essas estruturas, porque não basta ter software e hardware que...

Trabalhar em conjunto para treinar o modelo do passado, mas precisamos capacitar as pessoas para treinar. O modelo do futuro.

E se há algo que sabemos sobre IA generativa, é que ela está mudando rapidamente. E os sistemas do passado, os modelos do passado, não são os mesmos que... Os modelos do futuro.

E assim, temos trabalhado arduamente para proporcionar tanto uma eficiência incrível quanto uma flexibilidade incrível para os pesquisadores que desenvolvem a tecnologia de o futuro.

Implementar IA generativa também é um grande desafio. E talvez alguns de vocês já tenham experimentado isso ao usar algumas das demonstrações e sistemas protótipos disponíveis. A velocidade necessária para gerar uma imagem ou um texto pode, na verdade, tornar o uso dessas ferramentas mais lento e criar atritos.

E é evidente que, se conseguíssemos reduzir o tempo necessário para gerar amostras a partir desses modelos, poderíamos vê-los implementados de forma mais ampla. Também é interessante notar que, no passado, projetamos sistemas com foco principal no treinamento, pois o objetivo era gerar tecnologia inédita, o que exigia um investimento enorme em treinamento.

Mas agora que esses modelos estão começando a ser amplamente utilizados e são tão gerais, estamos começando a ver que o processamento computacional está se voltando para a inferência.

E esse é um desafio empolgante, eu acho, para a indústria: descobrir como tornar esses modelos o mais eficientes possível para que possam ser implementados da forma mais ampla possível.

E talvez você já tenha ouvido falar do paradoxo de Jevons. É a ideia de que, se você conseguir tornar algo mais barato de usar, a demanda agregada aumentará. E isso tem sido observado em muitos campos diferentes da economia ao longo dos séculos.

E acho que isso também se aplica à IA generativa, o que significa que a escala de aplicação dessas tecnologias será extremamente linear em função da eficiência com que conseguirmos implementá-las.

Portanto, se conseguirmos tornar a implementação um pouco mais eficiente, haverá muito mais aplicações novas para essa tecnologia. Às vezes, é até melhor usar uma API do que implementar um modelo por conta própria, e a NVIDIA está trabalhando nisso. também.

Estivemos falando sobre algumas das APIs que estamos criando para Nemo, Picasso e BioNemo, e esses modelos estão sendo executados em... várias nuvens às quais podemos fornecer acesso.

E acredito que, daqui para frente, veremos muitas empresas, incluindo a NVIDIA, investindo na criação de APIs e infraestrutura para que diversas empresas possam implantar IA generativa e personalizá-la para seus próprios usos comerciais.

A IA generativa está nos conduzindo a um novo tipo de economia, uma economia pós-escassez para o trabalho intelectual. Ela está direcionando nossos esforços para um nível mais elevado de abstração. A quantidade de conteúdo está se tornando menos importante.

Talvez você se lembre de quando estava na escola e seu professor pedia: "Por favor, escreva um trabalho de 10 páginas sobre algum assunto". Mas por que ele pedia 10 páginas?

Bem, parte disso refletia a verdade de que, para expressar uma ideia importante, ela precisa ser totalmente elaborada, e isso ocupa espaço.

Parte disso refletia o trabalho necessário para realmente gerar ideias que pudessem preencher esse espaço. E muitos de nós estávamos acostumados com a ideia de que o tamanho do conteúdo que criávamos estava correlacionado ao seu valor.

E acho que isso é verdade e continua sendo verdade, mas também é o caso de que, em um mundo com IA generativa, onde podemos criar conteúdo, seja texto ou outras coisas, com muita facilidade, o tamanho do conteúdo será muito menos importante do que o valor das ideias, a qualidade das ideias.

E acho que isso é um desenvolvimento empolgante. Acho que significa que, em vez de pensarmos tanto se conseguimos produzir uma certa quantidade de conteúdo, vamos nos concentrar mais no propósito desse conteúdo, no que ele significa e em como reagimos a ele.

Isso nos toca? O que isso nos ensina?

É factual? É correto? É, sabe, um argumento que possa nos ensinar algo?

E acredito que ter ferramentas que nos permitam ampliar e desenvolver nossas ideias com IA nos ajudará a explorá-las mais profundamente e, em última análise, a aprender coisas novas como sociedade. Portanto, acho que isso será realmente empolgante e importante.

Isso vai gerar mais produtividade para todos nós que realizamos trabalho intelectual. Também precisamos pensar em qual será o enquadramento do modelo. Já vi muitas vezes, ao implementar IA na NVIDIA, que a diferença entre o sucesso e o fracasso de um determinado modelo pode depender das entradas e das saídas do modelo.

O modelo em si pode ser bom, mas se for implementado com entradas incorretas, produzirá resultados ruins e será insuficiente para a tarefa.

E com a IA generativa não é diferente. É necessário um trabalho enorme para descobrir como um modelo pode ser implementado.

Às vezes, chamamos parte desse trabalho de engenharia de prompts. Então, com qualquer um desses modelos de texto, sejam modelos de texto para imagem ou modelos de linguagem, você sabe, existem várias maneiras de formular a pergunta.

Existem várias instruções que você pode fornecer ao modelo em formato de texto para indicar o que deseja e influenciar o resultado. E, sabe, o processo de explorar como descrever instruções para o modelo a fim de obter o resultado desejado, e como adicionar instruções que ajudem as pessoas a resolver tipos específicos de problemas em domínios específicos.

Chamamos isso de engenharia de prompts, e é algo muito importante. Para muitas das imagens da minha apresentação, usei um modelo generativo, e a qualidade dos resultados que obtenho desse modelo depende muito da qualidade da pergunta que faço. Portanto, há um novo tipo de habilidade, um novo tipo de criatividade que surge ao interagir com esses modelos, onde você descobre como fazer perguntas de maneiras mais úteis.

E isso será valioso. As pessoas que experimentarem esses modelos e aprenderem como eles funcionam conseguirão realizar mais com eles.

Também estamos investindo bastante em mecanismos de proteção. E isso se refere a modelos que talvez envolvam o modelo central ou heurísticas, proporcionando mais segurança, mais verificação de fatos e mais controle sobre a propriedade intelectual.

E acredito que veremos mais investimentos nessa área ao longo do tempo. O principal desafio da IA generativa é o controle. Você tem um modelo muito poderoso que pode gerar qualquer coisa, mas você só quer que ele gere algumas coisas específicas.

É difícil dizer exatamente o que você deseja gerar. Como você descreve o modelo? Como você cria um ambiente onde seja seguro usar esse modelo?

Essa é a questão central em que estamos trabalhando. E há muito investimento sendo feito em mecanismos de proteção para o modelo. E sempre acho que vale a pena lembrar desta citação de George Box, um famoso estatístico, que disse que todos os modelos estão errados ou alguns são úteis. E a questão é: como tornamos esses modelos generativos úteis?

Há muito trabalho envolvido na forma como o modelo é implementado, que não tem a ver com o modelo em si, mas sim com a estrutura que o envolve, a qual é fundamental para se obter algo que realmente resolva um problema.